

EXAM : Modèle linéaire

La durée de l'examen est 3 heures. Les calculatrices, téléphones portables et ordinateurs sont interdits. Pour chaque étudiant, une feuille A4 recto-verso est autorisée. Chaque réponse doit être justifiée. Des points seront attribués pour la présentation.

Questions générales

- 1) Soit X et Y deux vecteurs Gaussiens indépendants de dimension respective p et q . Donner la loi de $AX + BY$ en fonction des moyennes (μ_X et μ_Y) et covariances (Σ_X et Σ_Y) de X et Y , où $A \in \mathbb{R}^{2 \times p}$ et $B \in \mathbb{R}^{2 \times q}$ sont des matrices déterministes.
- 2) Soit y_1, y_2, \dots, y_n i.i.d. tel que $\mathbb{E}[y_1^2] < \infty$. Soit $(w_i)_{1 \leq i \leq n}$ un vecteur de poids positifs et déterministes. Quel estimateur $\hat{\mu}$ minimise $\sum_{i=1}^n w_i (y_i - \mu)^2$? Donner son biais et sa variance, pour tout $n > 1$.
- 3) Soit y_1, y_2, \dots, y_n i.i.d. tel que $\mathbb{E}[y_1^2] < \infty$. Soit $(w_i)_{1 \leq i \leq n}$ un vecteur de poids positifs et déterministes. Quel estimateur $\hat{\mu}$ minimise $\sum_{i=1}^n w_i (y_i - \mu)^2 + \lambda \mu^2$? Donner son biais et sa variance, pour tout $n > 1$.
- 4) On observe un échantillon i.i.d. $(X_i)_{1 \leq i \leq n}$. On note $\sigma^2 = \text{Var}(X_1)$. Donner un estimateur sans biais de σ^2 . Justifier.
- 5) La fonction $x \mapsto e^{-x^2}$, définie sur \mathbb{R} , est-elle convexe? Est-elle concave?
- 6) On note A^+ la pseudo-inverse de A . En utilisant la SVD de X (dont on introduira les notations), montrer que $X(X^T X)^+ X^T$ est un projecteur orthogonal. On précisera son espace image.
- 7) Donner le projeté orthogonal du vecteur $Y \in \mathbb{R}^n$ sur $\text{Vect}(e_k)$, avec e_k le k -ème vecteur de la base canonique de \mathbb{R}^n .
- 8) Montrer que pour toute matrice A , $\ker(A) = \ker(A^T A)$.

Moindres carrés : $Y = (y_1, \dots, y_n)^T \in \mathbb{R}^n$ et $X = (1_n, \tilde{X}) \in \mathbb{R}^{n \times (p+1)}$, $1_n = (1, \dots, 1)^T \in \mathbb{R}^n$.

9) Soit $\mu_n = \tilde{X}^T 1_n / n$ et $X_c = \tilde{X} - 1_n \mu_n^T$. Montrer que l'assertion " $\exists u \neq 0$ dans \mathbb{R}^{p+1} telle que $Xu = 0$ " est équivalente à " $\exists v \neq 0$ dans \mathbb{R}^p telle que $X_c v = 0$ ". En admettant que pour toute matrice A , $\ker(A) = \ker(A^T A)$, on exprimera la condition d'unicité des moindres-carrés à l'aide de la matrice de covariance empirique.

10) On suppose que X est de rang plein et on note $\hat{\theta}_n$ l'estimateur OLS. On note $\tilde{X} = (\tilde{X}_1, \dots, \tilde{X}_p)$. On change l'échelle d'une des variables : \tilde{X}_k est remplacé par $\tilde{X}_k b$, où $b > 0$.

(a) Soit $X_b = (1, X_1, \dots, X_k b, \dots, X_p)$. Montrer que $X_b = XD$ où D est une matrice diagonale que l'on précisera.

(b) Soit $\hat{\theta}_{b,n}$ l'estimateur OLS associé à X_b . Exprimer $\hat{\theta}_{b,n}$ en fonction de $\hat{\theta}_n$ et D .

(c) Donner la variance de $\hat{\theta}_{b,n}$.

(d) On a vu que l'estimateur $\hat{\theta}_n$ était affecté par un changement d'échelle. Qu'en est-il de la valeur prédite par le modèle ?

11) Donner la formulation de la pseudo inverse de X connaissant sa SVD (réduite) : $X = \sum_{i=1}^r s_i \mathbf{u}_i \mathbf{v}_i^T$, avec $r = \text{rg}(X)$ et $s_1 \geq \dots \geq s_r > 0$. A l'aide de cette dernière et du vecteur Y , exprimer l'estimateur OLS. On notera que X n'est pas nécessairement de rang plein ici.

12) Soit n un entier pair. Donner une formulè explicite du problème $\arg \min_{\theta \in \mathbb{R}^{p+1}} \frac{1}{2} (Y - X\theta)^T \Omega (Y - X\theta)$ pour une matrice $\Omega = \text{diag}(w_1, \dots, w_n)$ telle que $w_i = 1$ si i est pair et 0 si i est impair. Donner une condition équivalente à l'unicité des solutions.

Tests, intervalle de confiance et Bootstrap. On suppose toujours $Y = (y_1, \dots, y_n)^T \in \mathbb{R}^n$ et $X = (1_n, \tilde{X}) \in \mathbb{R}^{n \times (p+1)}$. On note $\theta^* = (\theta_0^*, \dots, \theta_p^*)^T \in \mathbb{R}^{p+1}$.

13) Dans le cas du modèle de régression (avec design déterministe) et bruit Gaussien centré de variance σ^2 , donner la loi de l'estimateur des moindres carrés $\hat{\theta}_n$ en supposant que X est de rang plein. Soit $x \in \mathbb{R}^{p+1}$ et l'hypothèse nulle $H_0 : x^T \theta^* = 10$. En déduire une statistique de test et une région critique à 95%.

14) Dans la cadre du modèle linéaire Gaussien avec matrice X de rang plein et bruits de variance σ^2 connue, donner la loi de la statistique $T = (\hat{\theta}_k - \theta_k^*) / \sqrt{\sigma^2 s_k}$, avec $s_k = e_k^T (X^T X)^{-1} e_k$, $k \in \{0, \dots, p\}$ et e_{k-1} le k -ème vecteur de la base canonique. En déduire un intervalle de confiance à 95% pour le paramètre θ_k^* .

15) Soient Z_1, \dots, Z_n des variables aléatoires i.i.d. d'espérance μ et de variance finie. Écrire un pseudo code de bootstrap pour le test sur la moyenne $\mu = 1$. On définira la racine \hat{R} et la racine bootstrap \hat{R}^* .

Ridge. A partir de maintenant $X \in \mathbb{R}^{n \times p}$. On note ici $\hat{\theta}_n = \arg \min_{\theta \in \mathbb{R}^p} \frac{1}{2} \|Y - X\theta\|_2^2 + \frac{\lambda}{2} \|\theta\|_2^2$ l'estimateur Ridge, où $\lambda > 0$.

✓ 16) Exprimer $\hat{\theta}_n$.

17) On rappelle la SVD complète $X = USV^T$ où $U \in \mathbb{R}^{n \times n}$ et $V \in \mathbb{R}^{p \times p}$.

(a) Montrer que

$$(X^T X + \lambda I_p)^{-1} X^T = X^T (X X^T + \lambda I_n)^{-1}$$

(hint : on utilisera ici la SVD complète de X)

(b) Si $n \ll p$, donner une formule alternative pour calculer l'estimateur Ridge avec moins d'opération. Comparer le nombre d'opérations nécessaires.

✓ 18) Donner une formule explicite de

$$\hat{\theta}_n = \arg \min_{\theta \in \mathbb{R}^p} (Y - X\theta)^T \Omega (Y - X\theta) + \lambda \|\theta\|_2^2,$$

pour une matrice diagonale $\Omega = \text{diag}(w_1, \dots, w_n)$ dont les coefficients sont strictement positifs.

✓ 19) Donner en tout point la sous-différentielle de la fonction réelle $x \mapsto \max(-x, 0)$.

20) Donner l'étape de mise à jour principale en descente par coordonnée pour résoudre le problème de l'Elastic Net : $\hat{\theta}_\lambda = \arg \min_{\theta \in \mathbb{R}^p} \left[\frac{1}{2} \|Y - X\theta\|_2^2 + \lambda \left(\alpha \|\theta\|_1 + (1 - \alpha) \frac{\|\theta\|_2^2}{2} \right) \right]$.